

IFT 615 – Intelligence artificielle

Recherche locale

Hugo Larochelle

Département d'informatique

Université de Sherbrooke

[http ://www.dmi.usherb.ca/~larocheh/cours/ift615.html](http://www.dmi.usherb.ca/~larocheh/cours/ift615.html)

Objectifs

- Comprendre :
 - ◆ la différence entre une recherche heuristique et une recherche locale
 - ◆ la méthode *hill-climbing*
 - ◆ la méthode *simulated annealing*
 - ◆ les algorithmes génétiques

Motivations pour une recherche locale

- Rappel de quelques faits saillants de A^* :
 - ◆ un noeud ou état final (le but) à atteindre est donné comme entrée
 - ◆ la solution est un chemin et non juste un noeud final
 - ◆ idéalement on veut un chemin optimal
 - ◆ les noeuds rencontrés sont stockés pour éviter de les revisiter
- Pour certains types de problèmes impliquant une recherche dans un espace d'états, on pourrait avoir les caractéristiques suivantes :
 - ◆ il y a une **fonction objectif** (*objective function*) à optimiser (possiblement avec une fonction but qui identifie un noeud final)
 - ◆ la solution recherchée est juste le noeud optimal (ou proche) et **non le chemin qui y mène**
 - ◆ l'espace d'états est trop grand pour enregistrer les noeuds visités
- Pour ce genre de problèmes, une recherche locale peut être la meilleure approche

Principe d'une recherche locale

- Une recherche locale garde juste certains noeuds visités en mémoire :
 - ◆ le cas le plus simple est *hill-climbing* qui garde juste **un noeud** (le noeud courant) et l'améliore itérativement jusqu'à converger à une solution
 - ◆ le cas le plus élaboré est celui des algorithmes génétiques qui gardent **un ensemble de noeuds** (appelé *population*) et le fait évoluer jusqu'à obtenir une solution
- En général, il y a une fonction objectif à optimiser, c.-à-d. maximiser ou minimiser
 - ◆ dans le cas de *hill-climbing*, elle permet de déterminer le noeud visité suivant
 - ◆ dans le cas des algorithmes génétiques, on l'appelle la **fonction de *fitness*** : elle intervient dans le calcul de l'ensemble des noeuds successeurs de l'ensemble courant
- En général, **une recherche locale ne garantit pas de solution optimale**
 - ◆ son attrait est surtout sa capacité de trouver une solution acceptable rapidement

Méthode *hill-climbing*


- Entrées :
 - ◆ noeud initial
 - ◆ fonction objectif à optimiser :
 - » notée $F(n)$ dans les algorithmes
- Méthode :
 - ◆ le nœud courant est initialisé au noeud initial
 - ◆ itérativement, le nœud courant est comparé à ses successeurs immédiats
 - » **le meilleur voisin n' immédiat** et ayant la plus grande valeur $F(n)$ que le nœud courant, devient le nœud courant
 - » **si un tel voisin n'existe pas, on arrête** et on retourne le nœud courant comme solution

Algorithme *hill-climbing*

Algorithme HILL-CLIMBING(*noeudInitial*) // *cette variante maximise*

1. déclarer deux nœuds : n, n'
2. $n = \text{noeudInitial}$
3. tant que (1) // *la condition de sortie (exit) est déterminée dans la boucle*
 4. $n' = \text{noeud successeur de } n \text{ ayant la plus grande valeur } F(n')$
 5. si $F(n') \leq F(n)$ // *si on minimisait, le test serait $F(n') \geq F(n)$*
 6. retourner n // *on n'arrive pas à améliorer p/r à $F(n)$*
7. $n = n'$

Illustration de l'algorithme *hill-climbing*



Imaginez ce que vous feriez pour arriver au (trouver le) sommet d'une colline donnée, en plein brouillard et souffrant d'amnésie.

Exemple de simulation de *hill-climbing*

- Soit la fonction objectif suivante, définie pour les entiers de 1 à 16 :

$n =$	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
$F(n) =$	4	6	15	5	3	2	4	5	6	7	8	10	9	8	7	3

- Quelle valeur de n trouverait la méthode *hill-climbing* si la valeur initiale de n était 6 et que les successeurs (voisins) utilisés étaient $n-1$ (seulement si $n > 1$) et $n+1$ (seulement si $n < 16$)?

Exemple de simulation de *hill-climbing*

- Soit la fonction objectif suivante, définie pour les entiers de 1 à 16 :



$n =$	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
$F(n) =$	4	6	15	5	3	2	4	5	6	7	8	10	9	8	7	3

- Quelle valeur de n trouverait la méthode *hill-climbing* si la valeur initiale de n était 6 et que les successeurs (voisins) utilisés étaient $n-1$ (seulement si $n > 1$) et $n+1$ (seulement si $n < 16$)?
- **Réponse:**
 - ♦ suite des valeurs de n parcourues: 6

Exemple de simulation de *hill-climbing*

- Soit la fonction objectif suivante, définie pour les entiers de 1 à 16 :

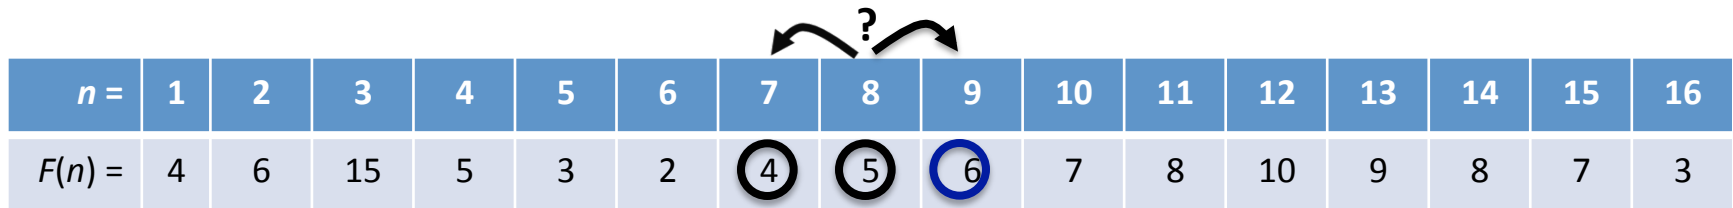


$n =$	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
$F(n) =$	4	6	15	5	3	2	4	5	6	7	8	10	9	8	7	3

- Quelle valeur de n trouverait la méthode *hill-climbing* si la valeur initiale de n était 6 et que les successeurs (voisins) utilisés étaient $n-1$ (seulement si $n > 1$) et $n+1$ (seulement si $n < 16$)?
- **Réponse:**
 - ♦ suite des valeurs de n parcourues: $6 \rightarrow 7$

Exemple de simulation de *hill-climbing*

- Soit la fonction objectif suivante, définie pour les entiers de 1 à 16 :

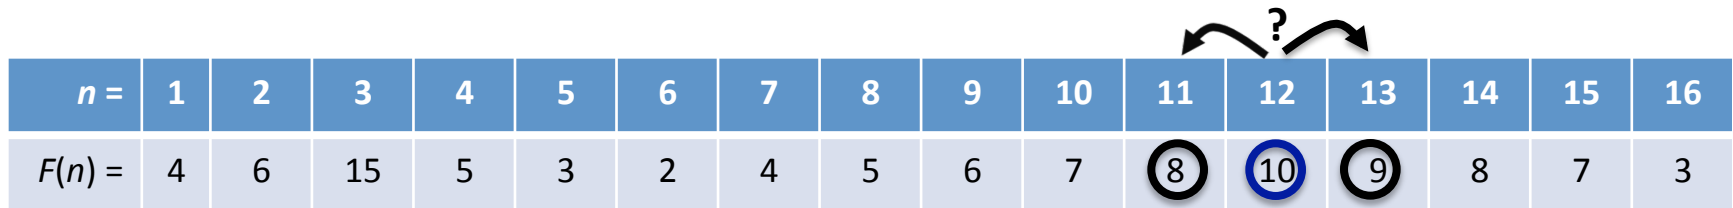


$n =$	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
$F(n) =$	4	6	15	5	3	2	4	5	6	7	8	10	9	8	7	3

- Quelle valeur de n trouverait la méthode *hill-climbing* si la valeur initiale de n était 6 et que les successeurs (voisins) utilisés étaient $n-1$ (seulement si $n > 1$) et $n+1$ (seulement si $n < 16$)?
- **Réponse:**
 - ◆ suite des valeurs de n parcourues: $6 \rightarrow 7 \rightarrow 8$

Exemple de simulation de *hill-climbing*

- Soit la fonction objectif suivante, définie pour les entiers de 1 à 16 :



$n =$	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
$F(n) =$	4	6	15	5	3	2	4	5	6	7	8	10	9	8	7	3

- Quelle valeur de n trouverait la méthode *hill-climbing* si la valeur initiale de n était 6 et que les successeurs (voisins) utilisés étaient $n-1$ (seulement si $n>1$) et $n+1$ (seulement si $n<16$)?
- **Réponse:**
 - ◆ suite des valeurs de n parcourues: $6 \rightarrow 7 \rightarrow 8 \rightarrow 9 \rightarrow 10 \rightarrow 11 \rightarrow 12$
 - ◆ *hill-climbing* termine et retourne $n=12$

Exemple : *N-Queen*

- Problème : Placer N reines sur un échiquier de taille $N \times N$ de sorte que deux reines ne s'attaquent pas mutuellement :
 - ◆ c-à-d., jamais deux reines sur la même diagonale, ligne ou colonne



Hill-climbing avec 8 reines


- n : configuration de l'échiquier avec N reines
- $F(n)$: nombre de paires de reines qui s'attaquent mutuellement directement ou indirectement dans la configuration n
- On veut le **minimiser**

18	12	14	13	13	12	14	14
14	16	13	15	12	14	12	16
14	12	18	13	15	12	14	14
15	14	14	♔	13	16	13	16
♔	14	17	15	♔	14	16	16
17	♔	16	18	15	♔	15	♔
18	14	♔	15	15	14	♔	16
14	14	13	17	12	14	12	18

- $F(n)$ pour l'état (noeud) affiché : 17
- Encadré : les meilleurs successeurs, si on bouge une reine dans sa colonne

Hill-Climbing avec 8 reines

- Un exemple de minimum local avec $F(n)=1$



Méthode *simulated annealing* (recuit simulé)

- C'est une amélioration de l'algorithme *hill-climbing* pour **minimiser le risque d'être piégé dans des maxima/minima locaux**
 - ◆ au lieu de regarder le meilleur voisin immédiat du nœud courant, **avec une certaine probabilité on va regarder un moins bon voisin immédiat**
 - » on espère ainsi s'échapper des optima locaux
 - ◆ au début de la recherche, la **probabilité de prendre un moins bon voisin** est plus élevée et **diminue graduellement**
- Le nombre d'itérations et la diminution des probabilités sont définis à l'aide d'un schéma (*schedule*) de « températures », en ordre décroissant
 - ◆ ex.: schéma [2^0 , 2^{-1} , 2^{-2} , 2^{-3} , ... , 2^{-99}], pour un total de 100 itérations
 - ◆ la meilleure définition du schéma va varier d'un problème à l'autre

Algorithme *simulated annealing*

Algorithme SIMULATED-ANNEALING(*noeudInitial*, *schema*) // *cette variante maximise*

1. déclarer deux nœuds : n, n'
2. déclarer : $t, T, \Delta E$,
3. $n = \text{noeudInitial}$
4. pour $t = 1 \dots \text{taille}(\text{schema})$
 5. $T = \text{schema}[t]$
 6. $n' =$ successeur de n choisi au hasard
 7. $\Delta E = F(n') - F(n)$ // *si on minimisait, $\Delta E = F(n) - F(n')$*
 8. si $\Delta E > 0$ alors assigner $n = n'$ // *amélioration p/r à n*
 9. sinon assigner $n = n'$ seulement avec probabilité de $e^{\Delta E / T}$
10. retourner n


plus T est grand,
plus $e^{\Delta E / T}$ est petite

D'autres améliorations: *tabu search*

- L'algorithme *simulated annealing* minimise le risque d'être piégé dans des optima locaux
- Par contre, il n'élimine pas **la possibilité d'osciller indéfiniment** en revenant à un noeud antérieurement visité
- **Idée:** On pourrait **enregistrer les noeuds visités**
 - ◆ on revient à A^* et approches similaires!
 - ◆ mais c'est impraticable si l'espace d'états est trop grand
- L'algorithme ***tabu search*** (recherche taboue) enregistre seulement les **k derniers noeuds visités**
 - ◆ l'**ensemble taboue** est l'ensemble contenant les k noeuds
 - ◆ le paramètre k est choisi empiriquement
 - ◆ cela n'élimine pas les oscillations, mais les réduit
 - ◆ il existe en fait plusieurs autres façon de construire l'ensemble taboue...

D'autres améliorations: *beam search*

- **Idée:** plutôt que maintenir un seul noeud solution n , on pourrait maintenir un ensemble de k noeuds différents
 1. on commence avec un ensemble de k noeuds choisis aléatoirement
 2. à chaque itération, tous les successeurs des k noeuds sont générés
 3. on choisit les k meilleurs parmi ces noeuds et on recommence
- Cet algorithme est appelé ***local beam search*** (exploration locale par faisceau)
 - ◆ à ne pas confondre avec *tabu search*
 - ◆ variante *stochastic beam search* : plutôt que prendre les k meilleurs, on assigne une probabilité de choisir chaque noeud, même s'il n'est pas parmi les k meilleurs (comme dans *simulated annealing*)

Algorithme génétique

- Très similaire à *local* ou *stochastic beam-search*
- **Algorithme génétique**
 - ◆ on commence aussi avec un ensemble de k noeuds choisis aléatoirement : cet ensemble est appelé une **population**
 - ◆ un successeur est généré en combinant deux parents
 - ◆ un noeud est représenté par un mot (chaîne) sur un alphabet (souvent l'alphabet binaire)
 - ◆ la fonction d'évaluation est appelée **fonction de *fitness*** (fonction d'adaptabilité, de survie)
 - ◆ la prochaine génération est produite par **(1) sélection, (2) croisement et (3) mutation**

Algorithme génétique

- Inspiré du processus de l'évolution naturelle des espèces :
 - ◆ après tout l'intelligence humaine est le résultat d'un processus d'évolution sur des millions d'années :
 - » théorie de l'évolution (Darwin, 1858)
 - » théorie de la sélection naturelle (Weismann)
 - » concepts de génétiques (Mendel)
 - ◆ la simulation de l'évolution n'a pas besoin de durer des millions d'années sur un ordinateur

Algorithme génétique


- On représente l'espace des solutions d'un problème à résoudre par une population (ensemble de **chromosomes**).
 - ◆ un chromosome est une chaîne de bits (**gènes**) de taille fixe
 - ◆ par exemple : 101101001
- Une population génère des enfants par un ensemble de procédures simples qui manipulent les chromosomes
 - ◆ **croisement de parents**
 - ◆ **mutation d'un enfant généré**
- Les enfants sont conservés en fonction de leur **adaptabilité** (*fitness*) déterminée par une fonction d'adaptabilité donnée $F(n)$

Algorithme génétique

Algorithme ALGORITHME-GÉNÉTIQUE($k, nb_iterations$) // *cette variante maximise*

1. $population =$ ensemble $\{n_1, n_2, \dots, n_k\}$ généré aléatoirement de k chromosomes
2. pour $t = 1 \dots nb_iterations$
 3. $nouvelle_population = \{\}$
 4. pour $i = 1 \dots k$
 5. $n =$ chromosome pris dans $population$ avec probabilité proportionnelle à $F(n)$
 6. $n' =$ chromosome différent pris dans $population - \{n\}$ de la même façon
 7. $n^* =$ résultat du croisement entre n et n'
 8. avec petite probabilité, appliquer une mutation à n^*
 9. ajouter n^* à $nouvelle_population$
 10. $population = nouvelle_population$
11. retourner chromosome n dans $population$ avec valeur de $F(n)$ la plus élevée

Croisement : exemple avec 8 reines



67247588

75251448


= 67251448

Exemple avec 8 reines



- Fonction de *fitness* : nombre de paires de reines qui ne s'attaquent pas (min = 0, max = $8 \times 7/2 = 28$)
- Probabilité de sélection du premier chromosome : **pourcentage de *fitness* parmi la population**
 - ◆ $24/(24+23+20+11) = 31\%$
 - ◆ $23/(24+23+20+11) = 29\%$
 - ◆ $20/(24+23+20+11) = 26\%$
 - ◆ $11/(24+23+20+11) = 14\%$

Exemple avec 8 reines



- Plusieurs autres choix de processus de sélection seraient valide
 - ◆ ex.: on pourrait ne jamais sélectionner les chromosomes faisant partie des 25% pires
- **L'important est que la probabilité qu'un chromosome n soit choisi augmente en fonction de sa valeur $F(n)$**

Autre Exemple

- Calculer le maximum de la fonction $F(n) = 15n - n^2$
- Supposons n entre $[0, 15]$:
 - ◆ on a besoin de seulement 4 bits pour représenter la population

Integer	Binary code	Integer	Binary code	Integer	Binary code
1	0 0 0 1	6	0 1 1 0	11	1 0 1 1
2	0 0 1 0	7	0 1 1 1	12	1 1 0 0
3	0 0 1 1	8	1 0 0 0	13	1 1 0 1
4	0 1 0 0	9	1 0 0 1	14	1 1 1 0
5	0 1 0 1	10	1 0 1 0	15	1 1 1 1

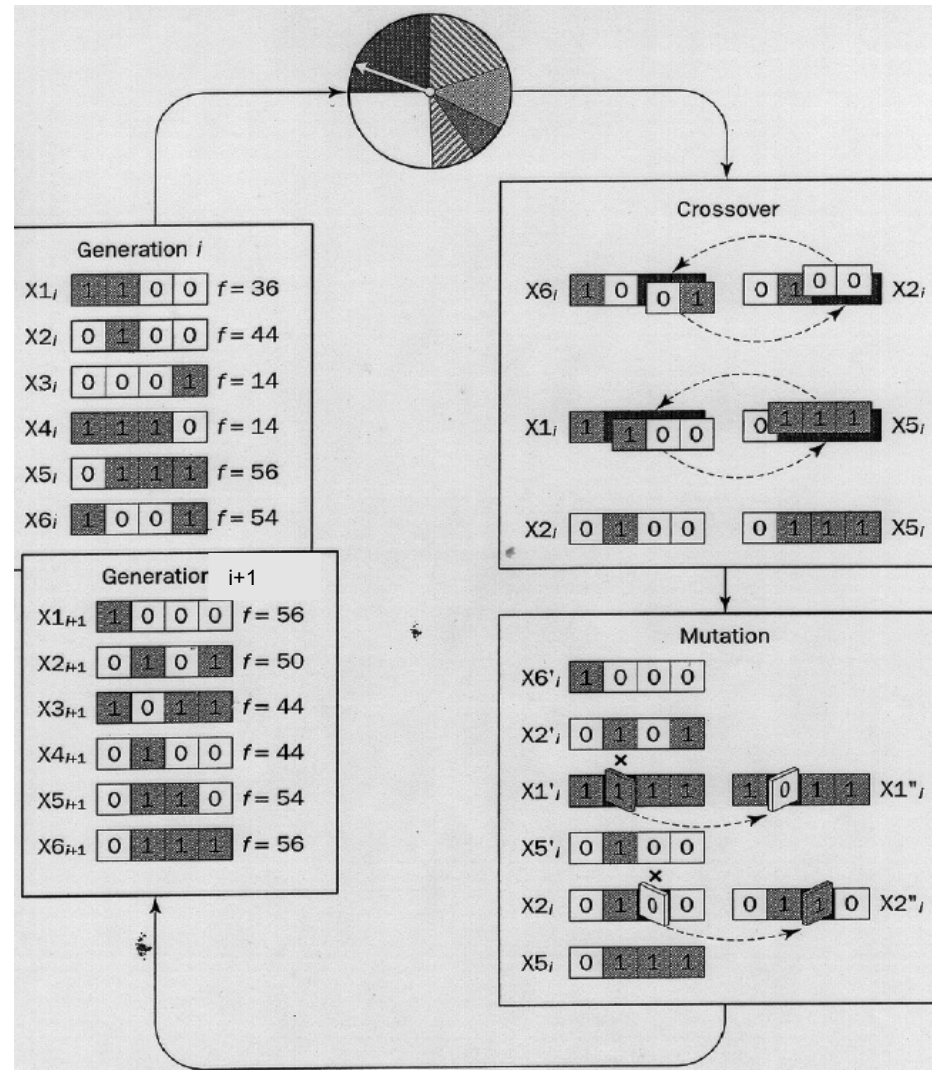
[Michael Negnevitsky. Artificial Intelligence. Addison-Wesley, 2002. Page 222.]

Autre Exemple (suite)

- Fixons la taille de la population à 6
- Et la probabilité de mutation à 0.001
- La fonction d'adaptabilité à $F(n) = 15n - n^2$
- L'algorithme génétique initialise les 6 chromosomes de la population en les choisissant au hasard

Chromosome label	Chromosome string	Decoded integer	Chromosome fitness	Fitness ratio, %
X1	1 1 0 0	12	36	16.5
X2	0 1 0 0	4	44	20.2
X3	0 0 0 1	1	14	6.4
X4	1 1 1 0	14	14	6.4
X5	0 1 1 1	7	56	25.7
X6	1 0 0 1	9	54	24.8

Autre Exemple (illustration des étapes)



Programmation génétique

- Même principes que les algorithmes génétiques sauf que les populations sont des programmes au lieu des chaînes de bits

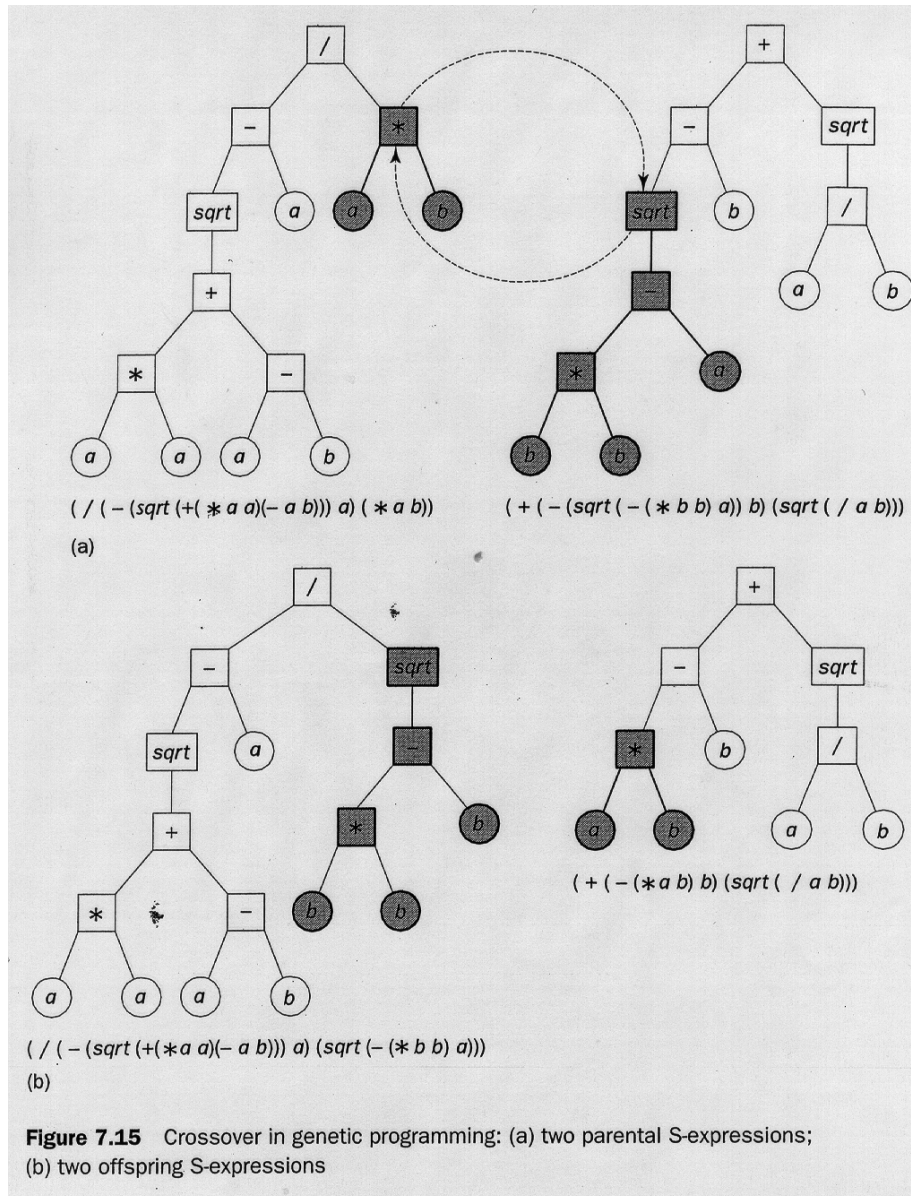




Figure 7.15 Crossover in genetic programming: (a) two parental S-expressions; (b) two offspring S-expressions




$(/ (- (\text{sqrt} (+ (* a a) (- a b))) a) (* a b))$

(a)




$(+ (- (\text{sqrt} (- (* b b) a)) b) (\text{sqrt} (/ a b)))$



$(/ (+ (\text{sqrt} (+ (* a a) (- a b))) a) (* a b))$

(b)

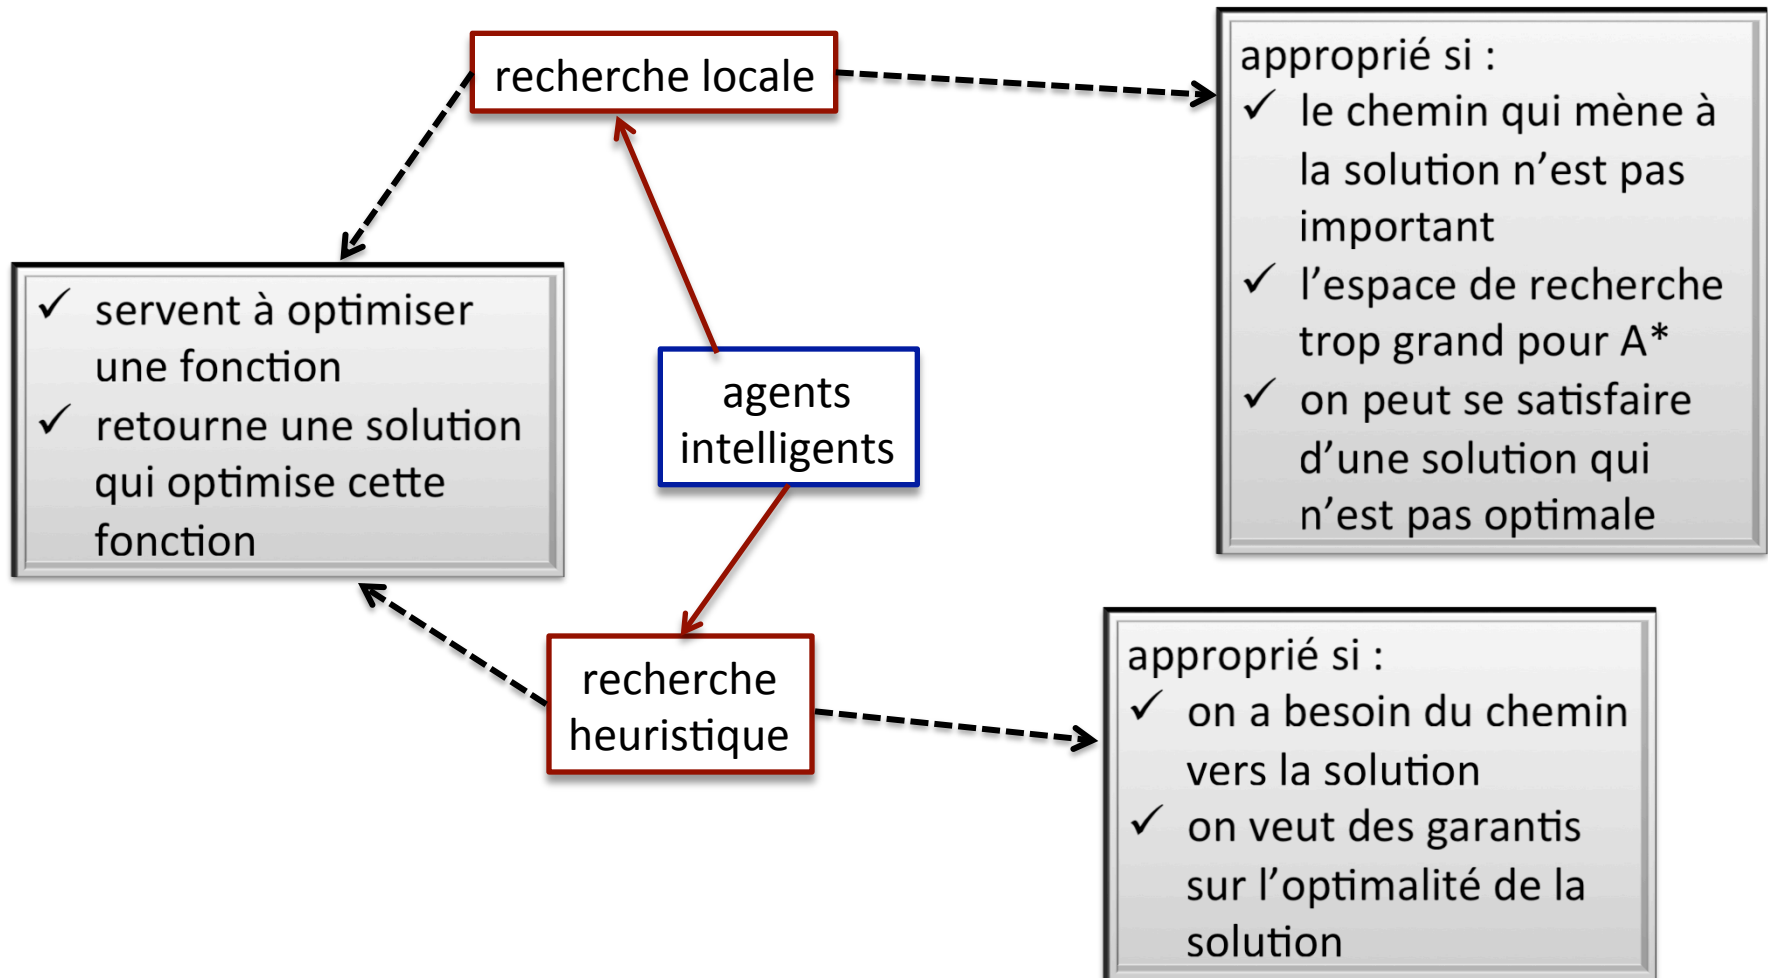


$(+ (- (\text{sqrt} (- (* b b) a)) a) (\text{sqrt} (/ a b)))$

Figure 7.16 Mutation in genetic programming: (a) original S-expressions; (b) mutated S-expressions


Objectifs du cours

Algorithmes et concepts

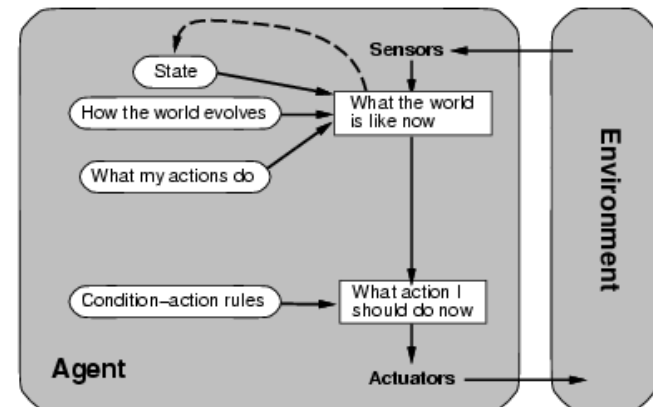


Recherche locale : pour quel type d'agent?

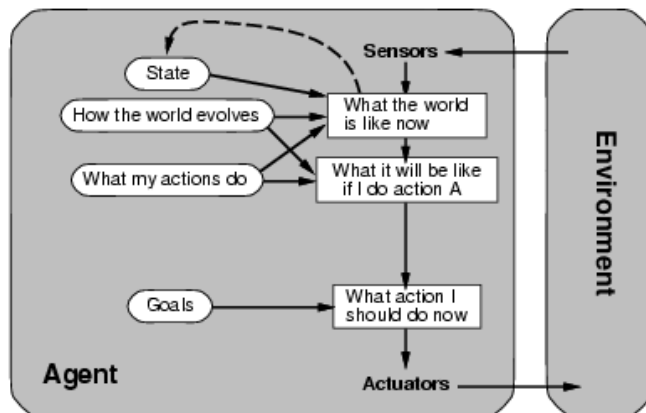
Simple reflex



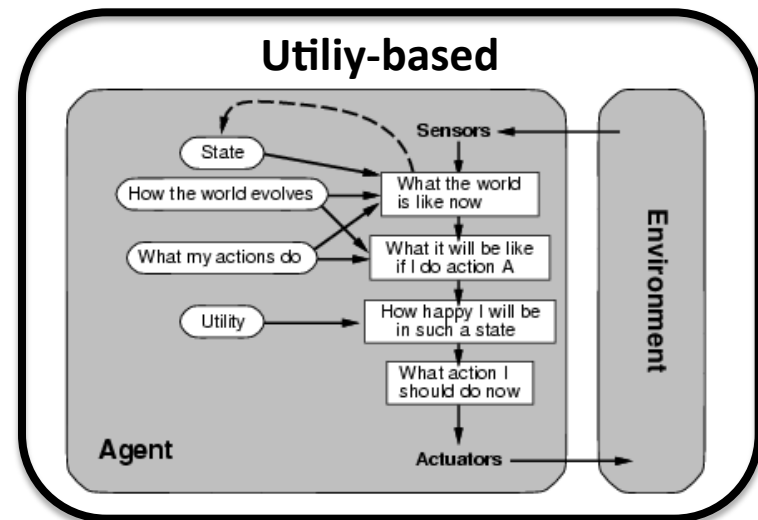
Model-based reflex



Goal-based



Utility-based



Conclusion

- La recherche locale est parfois une alternative plus intéressante que la recherche heuristique
- J'ai ignoré le cas où on a également une fonction but $goal(n)$
 - ◆ dans ce cas, lorsqu'on change la valeur de n , on arrête aussitôt que $goal(n)$ est vrai
 - » ex.: $goal(n)$ est vrai si n est un optimum global de $F(n)$
- La recherche locale va s'avérer utile plus tard dans le cours
 - ◆ satisfaction de contraintes
 - ◆ apprentissage par renforcement

Vous devriez être capable de...

- Décrire ce qu'est la recherche locale en général
- Décrire les algorithmes :
 - ◆ *hill-climbing*
 - ◆ *simulated annealing*
 - ◆ algorithme génétique
- Savoir simuler ces algorithmes
- Connaître leurs propriétés (avantages vs. désavantages)