

# **IFT 615 – Intelligence artificielle**

## **Réseaux bayésiens dynamiques**

Hugo Larochelle

Département d'informatique

Université de Sherbrooke

<http://www.dmi.usherb.ca/~larocheh/cours/ift615.html>

# Sujets couverts

- C'est quoi un réseau bayésien dynamique (RBD)?
- Exemple d'inférence simple dans un RBD
- Cas particuliers des modèles de Markov cachés

# Réseaux bayésiens dynamiques (RBD)


- Comment modéliser des situations dynamiques?
  - ◆ les changements dynamiques peuvent être vus **comme une séquence d'états**, chaque état représentant la situation à un instant  $t$  donné
  - ◆  $X_t$ : ensemble des **variables non observables (cachées)** décrivant l'état au temps  $t$
  - ◆  $E_t$ : ensembles de **variables observées (evidence)** au temps  $t$
- Le terme dynamique réfère au dynamisme du système qu'on veut modéliser et la structure du réseau

# Représentation dans un RBD


- Problème:
  - ◆ il faudrait spécifier un nombre infini de tables de probabilités conditionnelles, c.-à-d. une pour chaque variable, dans chaque état (chaque temps  $t$ )
  - ◆ chaque table pourrait impliquer un nombre infini de parents
- Solution:
  1. supposer que les changements dynamiques sont causés par un **processus stationnaire** - les probabilités ne changent pas dans le temps:  
 $P(X_t \mid \text{Parent}(X_t))$  **est la même** pour tous les  $t$
  2. supposer que les changements dynamiques sont causés par un **processus markovien** – l'état courant dépend seulement d'un nombre fini d'états précédents
    - » ex.: processus markoviens **du premier ordre**:
      - $P(X_t \mid X_{0:t-1}) = P(X_t \mid X_{t-1})$       modèle pour les transitions
  3. supposer que l'observation **dépend uniquement de l'état courant**
    - $P(E_t \mid X_{0:t}, E_{0:t-1}) = P(E_t \mid X_t)$       modèle pour les observations/capteurs

# Illustration d'un RDB

- Réseau bayésien dynamique (RBD) du premier ordre avec une seule variable  $X$ , répliquées dans les différents états pour modéliser la dynamique du système:




- RBD du second ordre:



# Exemple

- « Un gardien de sécurité passe un mois dans un édifice sous-terrain, sans sortir. Chaque jour, son directeur arrive avec ou sans parapluie. Le gardien veut inférer la possibilité qu'il ait plu ou non en fonction des séquences d'observation du parapluie. »
- Modélisation:
  - ◆ Variables:  $X_t = \{R_t\}$  (pour « *Rain* ») et  $E_t = \{U_t\}$  (pour « *Umbrella* »).
  - ◆ Dépendances entre les variables (c.-à-d., le RBD):



- ◆ Modèle des transitions:  $\mathbf{P}(R_t \mid R_{t-1})$ . Modèle d'observation:  $\mathbf{P}(U_t \mid R_t)$

# RBD

- Comment rendre un RBD plus précis?
  - ◆ **augmenter l'ordre du modèle markovien**
    - » ex.:  $Rain_t$  aurait comme parents, non seulement  $Rain_{t-1}$  mais aussi  $Rain_{t-2}$  pour un processus markovien du second ordre
    - » ceci donnerait des prédictions plus précises
  - ◆ **augmenter le nombre de variables d'états**
    - » par exemple on pourrait ajouter:
      - une variable  $Season_t$  pour tenir compte des statistiques historiques sur les temps de pluie selon les saisons
      - des variables  $Temperature_t$ ,  $Humidity_t$  and  $Pressure_t$  pour tenir compte de la physique des conditions de pluie
  - ◆ **permettre des interactions directes entre la variables d'observation**
    - » on pourrait avoir plutôt  $P(E_t \mid X_{0:t}, E_{0:t-1}) = P(E_t \mid X_t, E_{t-1})$
    - » ça peut rendre l'inférence encore plus complexe

# Types d'inférence dans un RBD

- **Filtrage (*filtering*)**: calcul de l'état de croyance (*belief state*), c.-à-d. la distribution a posteriori de la variable cachée la plus récente
  - ◆  $P(X_t | e_{1:t})$
- **Prédiction**: calculer la distribution a posteriori sur un état futur
  - ◆  $P(X_{t+k} | e_{1:t})$  où  $k > 0$
- **Lissage (*smoothing*)**: calculer la distribution a posteriori sur un état passé
  - ◆  $P(X_k | e_{1:t})$  où  $0 \leq k < t$
- **Explication la plus plausible**: trouver la séquence d'états cachés qui explique le mieux les observations
  - ◆  $\operatorname{argmax}_{X_{1:t}} P(x_{1:t} | e_{1:t}) = \operatorname{argmax}_{X_{1:t}} P(x_{1:t}, e_{1:t}) / P(e_{1:t}) = \operatorname{argmax}_{X_{1:t}} P(x_{1:t}, e_{1:t})$
- En plus, on pourrait vouloir faire de l'**apprentissage**: trouver les tables de probabilités conditionnelles telles que **nos données observées sont le plus vraisemblable possible** (à voir plus tard dans le cours)



# Filtrage avec RBD

- Calculer l'**état de croyance** (*belief state*) – c.-à-d., la distribution de probabilité a posteriori de l'état courant, étant données les observations jusque là:

$$\mathbf{P}(X_t \mid e_{1:t})$$

- Un agent intelligent a besoin du filtrage pour maintenir à jour son état courant
  - ◆ ceci est nécessaire pour prendre des décisions rationnelles (déterminer l'action appropriée étant donné l'état courant)

# Filtrage avec RBD

- Étant donnés les résultats du filtrage jusqu'au temps  $t$ , on peut facilement calculer le filtrage au temps  $t+1$  à partir des nouvelles observations  $e_{t+1}$
- En appliquant la règle de Bayes et l'hypothèse markovienne, nous arrivons à:

$$\mathbf{P}(X_{t+1} \mid e_{1:t+1}) = \mathbf{P}(X_{t+1} \mid e_{1:t}, e_{t+1}) \quad (\text{détails page 572 du manuel de référence})$$


$$= \alpha \underbrace{P(e_{t+1} \mid X_{t+1})}_{\text{probabilité de la nouvelle observation (disponible dans la table des probabilités)}} \sum_{x_t} \underbrace{\mathbf{P}(X_{t+1} \mid x_t) P(x_t \mid e_{1:t})}_{\text{prédiction du prochain état en se basant sur notre état de croyance au temps } t}$$

$\alpha$ : constante de normalisation

# Exemple de l'agent de sécurité

- RBD:

- ◆ une distribution de **probabilité a priori**  $P(R_0)$ , par exemple  $\langle 0.5, 0.5 \rangle$
- ◆ un **modèle des transition**  $P(R_t | R_{t-1})$
- ◆ un **modèle d'observation**  $P(U_t | R_t)$



$R_{t-1}$	$P(r_t   R_{t-1})$
T	0.7
F	0.3


  

$R_t$	$P(u_t   R_t)$
T	0.9
F	0.2

- **Jour 1:** le parapluie apparait, ( $U_1 = \text{true}$  ou  $u_1$ )

- ◆ le filtrage de  $t=0$  à  $t=1$  est:  $P(R_1 | u_1) = \alpha P(u_1 | R_1) P(R_1)$

# Exemple de l'agent de sécurité



- **Jour 2:** le parapluie apparait de nouveau, c.-à-d.,  $U_2 = \text{true}$ 
  - ◆ le filtrage de  $t=1$  à  $t=2$  est:

$$\begin{aligned} \mathbf{P}(R_2 \mid u_1, u_2) &= \alpha P(u_2 \mid R_2) \mathbf{P}(R_2 \mid u_1) \\ &= \alpha P(u_2 \mid R_2) \sum_{r_1} \mathbf{P}(R_2 \mid r_1) P(r_1 \mid u_1) \end{aligned}$$

# Chaînes de Markov

- Une **chaîne de Markov** (de premier ordre) est un cas particulier de RBD avec **une seule** variable aléatoire **discrète**  $S_t$  dans l'état au temps  $t$
- Le domaine de  $S_t$  est souvent un symbole (ex.: un caractère, un mot, etc.)
- Une **distribution a priori** (initiale) de probabilités sur les symboles (états) est spécifiée  $\mathbf{P}(S_1)$
- Une **matrice de transition** contenant les probabilités conditionnelles  $\mathbf{P}(S_{t+1} \mid S_t)$

# Illustration


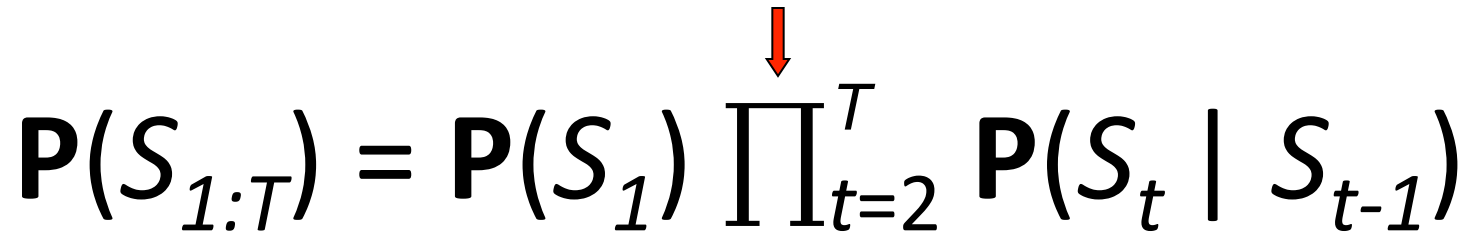


Illustration dans le cas d'une **chaîne finie**

# Probabilité de générer une chaîne

produit des probabilités, une pour  
chaque terme de la séquence



The diagram shows the formula  $P(S_{1:T}) = P(S_1) \prod_{t=2}^T P(S_t | S_{t-1})$ . A red arrow points down to the product symbol  $\prod$ . A blue arrow points up from the text 'distribution initiale de probabilités' to  $P(S_1)$ . Another blue arrow points up from the text 'distribution de transition' to  $P(S_t | S_{t-1})$ . A third blue arrow points up from the text 'une séquence de symboles, allant du temps 1 au temps T' to  $P(S_{1:T})$ .

$$P(S_{1:T}) = P(S_1) \prod_{t=2}^T P(S_t | S_{t-1})$$

distribution initiale  
de probabilités

distribution de  
transition

une séquence de  
symboles, allant du  
temps 1 au temps  $T$

# Visualisation d'une chaîne de Markov

Représentation matricielle

Symbole actuel

Prochain  
symbole

	<i>a</i>	<i>b</i>	<i>c</i>
<i>a</i>	.7	.3	0
<i>b</i>	.2	.7	.5
<i>c</i>	.1	0	.5

Représentation graphique




Illustration dans le cas d'une **chaîne infinie** (flux de symboles)

Exemple de chaîne: *ccb bbb aaaa a b a a b a c b a b a a a*



# Apprendre la table des probabilités conditionnelles

- Observer plusieurs chaînes et définir les probabilités conditionnelles en fonction des fréquences d'occurrence des symboles

$$P(B=b|a) = \frac{\sum_{\text{chaînes}} \text{freq}(a,b)}{\sum_{\text{chaînes}} \text{freq}(a)}$$

- Pour éviter les problèmes avec zéro occurrences, on utilise plutôt:

$$P(B=b|A=a) = \frac{1 + \sum_{\text{chaînes}} \text{freq}(a,b)}{\text{Nb. symboles} + \sum_{\text{chaînes}} \text{freq}(a)}$$

# Modèle de Markov caché

- Dans un **modèle de Markov caché** (*hidden Markov model* ou **HMM**):
  - ◆ il y a des **variables cachées**  $H_t$  et des **variables d'observation**  $S_t$ , toutes les deux discrètes
  - ◆ la chaîne de Markov est sur les variables cachées  $H_t$
  - ◆ le symbole émis (observé)  $S_t=s_t$  dépend uniquement de la variable cachée actuelle  $H_t$

# Illustration





Illustration dans le cas d'une **chaîne finie**

# Probabilité de générer une séquence cachée et une séquence visible



# Simuler d'un HMM

- Il est facile de générer des observations d'un HMM
  - ◆ échantillonner une valeur initiale  $H_1 = h_1$  de  $\mathbf{P}(H_1)$
  - ◆ pour  $t = 2$  jusqu'à  $T$ , répéter les deux échantillonnage suivants:
    - » utiliser les probabilités de transition de l'état caché courant pour obtenir un échantillon  $h_t$ , sachant l'état caché précédent:  $\mathbf{P}(H_t \mid H_{t-1} = h_{t-1})$
    - » utiliser les probabilités de sortie de la variable d'observation étant donné l'état caché courant, pour obtenir le symbole d'observation (émission)  $s_t$ :  $\mathbf{P}(S_t \mid H_t = h_t)$
- On peut aussi générer la séquence des états cachés d'abord et ensuite générer les observations
  - ◆ les variables cachées dépendent uniquement des variables cachées précédentes
  - ◆ chaque émission ne dépendra pas des autres émissions

# Illustration

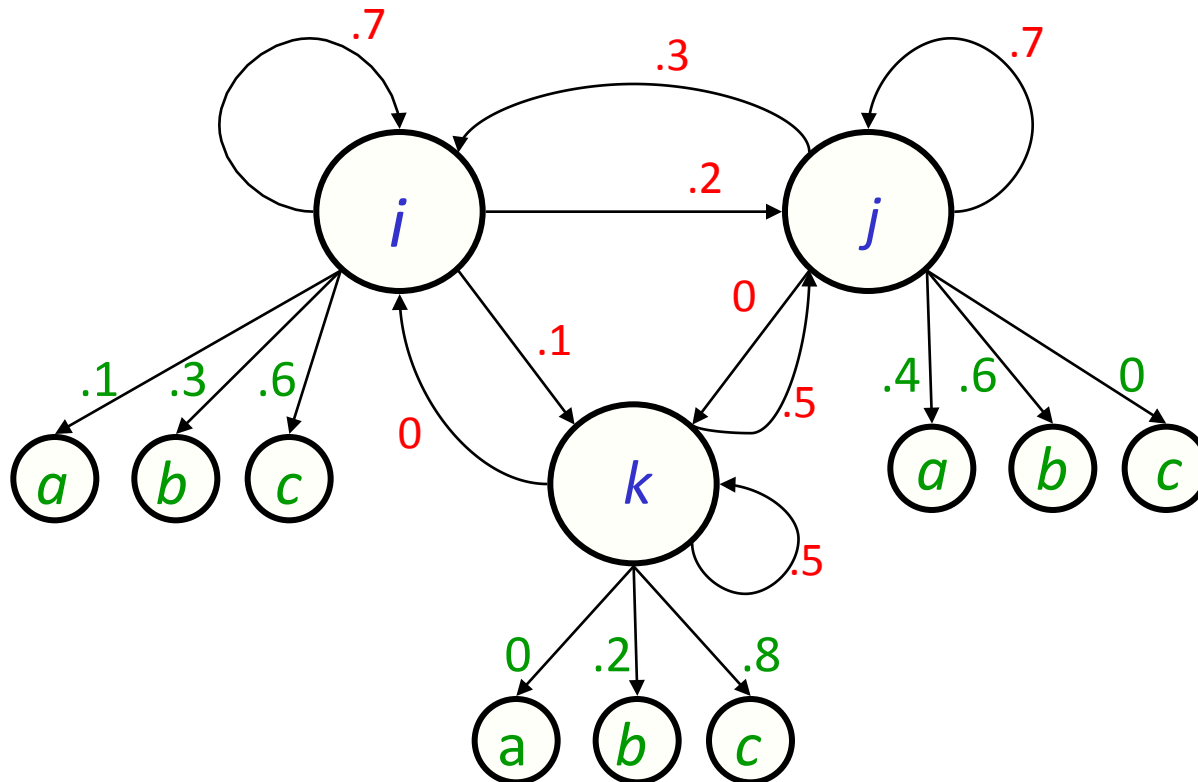


Illustration dans le cas d'une **chaîne infinie**, avec visualisation des valeurs de la variable cachée et la variable d'observation

Chaque **nœud caché** (valeur possible  $h$  de  $H$ ) a un vecteur de **probabilités de transitions** et un **vecteur de probabilités de sorties (observations)**

# Probabilité de générer une séquence visible

- La même séquence de sortie peut être produite par plusieurs séquences cachées différentes
- En fait, il y a un nombre exponentiel de séquences cachées possibles
- Un calcul naïf est donc très inefficace

$$\mathbf{P}(S_{1:T}) = \sum_{h_{1:T}} P(H_{1:T} = h_{1:T}) \mathbf{P}(S_{1:T} \mid H_{1:T} = h_{1:T})$$

# Programmation dynamique pour HMM

- Une façon plus efficace de calculer la probabilité d'une séquence observée  $s_{1:T}$
- Idée: utiliser la **programmation dynamique**
  - ◆ on définit  $\alpha(i,t) = P(S_{1:t}=s_{1:t}, H_t = i)$
  - ◆ on note la récursion
$$\begin{aligned}\alpha(i,t+1) &= P(S_{1:t+1}=s_{1:t+1}, H_{t+1} = i) \\ &= \sum_j P(S_{1:t+1}=s_{1:t+1}, H_t = j, H_{t+1} = i) \\ &= P(S_{t+1}=s_{t+1} | H_{t+1} = i) \sum_j P(H_{t+1} = i | H_t = j) P(S_{1:t}=s_{1:t}, H_t = j) \\ &= P(S_{t+1}=s_{t+1} | H_{t+1} = i) \sum_j P(H_{t+1} = i | H_t = j) \alpha(j,t)\end{aligned}$$
  - ◆ on a les valeurs initiales
$$\alpha(i,1) = P(S_1=s_1, H_1 = i) = P(S_1=s_1 | H_1 = i) P(H_1 = i) \quad \forall i$$
- Une fois le tableau  $\alpha$  calculé, on obtient facilement:
$$P(S_{1:T}=s_{1:T}) = \sum_j P(S_{1:T}=s_{1:T}, H_T = j) = \sum_j \alpha(j,T)$$



# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$		1	2	3	4
i \ t					
0					
1					

- initialisation:  $\alpha(i,1) = P(S_1=s_1, H_1 = i) = P(S_1=s_1 | H_1 = i) P(H_1 = i)$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$		1	2	3	4
i	t				
0		0.45			
1					

- initialisation:  $\alpha(0,1) = P(S_1=0 \mid H_1=0) P(H_1=0) = 0.9 \times 0.5 = 0.45$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$		1	2	3	4
i	t				
0		0.45			
1		0.1			

- initialisation:  $\alpha(1,1) = P(S_1=0 | H_1 = 1) P(H_1 = 1) = 0.2 \times 0.5 = 0.1$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$		t	1	2	3	4
i	0	0.45				
	1	0.1				

- récursion ( $t=1$ ):  $\alpha(i,t+1) = P(S_{t+1} = s_{t+1} | H_{t+1} = i) \sum_j P(H_{t+1} = i | H_t = j) \alpha(j,t)$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8


Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$		1	2	3	4
i	t				
0		0.45			
1		0.1			



- réursion:  $\alpha(0,2) = P(S_2=1 | H_2=0) ( P(H_2=0 | H_1=0) \alpha(0,1) + P(H_2=0 | H_1=1) \alpha(1,1) )$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$	$i \backslash t$	1	2	3	4
	0	0.45	0.0175		
	1	0.1			

- réursion:  $\alpha(0,2) = 0.1 (0.3 \times 0.45 + 0.4 \times 0.1) = 0.0175$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$		1	2	3	4
i	t				
0		0.45	0.0175		
1		0.1			

- réursion:  $\alpha(1,2) = P(S_2=1 | H_2=1) ( P(H_2=1 | H_1=0) \alpha(0,1) + P(H_2=1 | H_1=1) \alpha(1,1) )$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$		1	2	3	4
i	t				
0		0.45	0.0175		
1		0.1	0.3		

- réursion:  $\alpha(1,2) = 0.8 \ (0.7 \times 0.45 + 0.6 \times 0.1) = 0.3$



# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$		1	2	3	4
i	t	0.45	0.0175		
		0.1	0.3		

- réursion ( $t=2$ ):  $\alpha(i,t+1) = P(S_{t+1} = s_{t+1} | H_{t+1} = i) \sum_j P(H_{t+1} = i | H_t = j) \alpha(j,t)$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$		1	2	3	4
i	t				
0		0.45	0.0175	0.112725	
1		0.1	0.3		

- réursion:  $\alpha(0,3) = 0.9 (0.3 \times 0.0175 + 0.4 \times 0.3) = 0.112725$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$		1	2	3	4
i	t				
0		0.45	0.0175	0.112725	0.04427
1		0.1	0.3	0.03845	0.02039

- on continue d'appliquer la récursion jusqu'à la fin ( $t=4$ )...

# Filtrage dans un HMM

- Exemple: décoder un message binaire avec canal bruité (T=4)
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

$\alpha(i,t)$	$i \backslash t$				
		1	2	3	4
0		0.45	0.0175	0.112725	0.04427
1		0.1	0.3	0.03845	0.02039

- on peut calculer les probabilités de filtrage

$$\begin{aligned}
 P(H_4 = 0 \mid S_1=0, S_2=1, S_3=0, S_4=0) &= \frac{P(H_4 = 0, S_1=0, S_2=1, S_3=0, S_4=0)}{\sum_i P(H_4 = i, S_1=0, S_2=1, S_3=0, S_4=0)} \\
 &= \alpha(0,4) / ( \alpha(0,4) + \alpha(1,4) ) \\
 &= 0.04427 / (0.04427 + 0.02039) \\
 &\approx 0.6847
 \end{aligned}$$

$$\begin{aligned}
 P(H_4 = 1 \mid S_1=0, S_2=1, S_3=0, S_4=0) &= 0.02039 / (0.04427 + 0.02039) \\
 &\approx 0.3153
 \end{aligned}$$

# Programmation dynamique pour HMM

- Le calcul des  $\alpha(i,t)$  donne un balayage de gauche à droite
- On peut faire la même chose, mais de droite à gauche
  - ◆ on définit  $\beta(i,t) = P(S_{t+1:T}=s_{t+1:T} \mid H_t = i)$
  - ◆ on note la récursion
$$\begin{aligned}\beta(i,t-1) &= P(S_{t:T}=s_{t:T} \mid H_{t-1} = i) \\ &= \sum_j P(S_{t:T}=s_{t:T}, H_t = j \mid H_{t-1} = i) \\ &= \sum_j P(S_t = s_t \mid H_t = j) P(H_t = j \mid H_{t-1} = i) P(S_{t+1:T}=s_{t+1:T} \mid H_t = j) \\ &= \sum_j P(S_t = s_t \mid H_t = j) P(H_t = j \mid H_{t-1} = i) \beta(j,t)\end{aligned}$$
  - ◆ on a les valeurs initiales  $\beta(i,T) = 1 \forall i$
- Une fois le tableau  $\beta$  calculé, on obtient facilement:
$$\begin{aligned}P(S_{1:T}=s_{1:T}) &= \sum_j P(S_{1:T}=s_{1:T}, H_1 = j) \\ &= \sum_j P(S_{2:T}=s_{2:T} \mid H_1 = j) P(S_1=s_1 \mid H_1 = j) P(H_1 = j) \\ &= \sum_j \beta(j,1) P(S_1=s_1 \mid H_1 = j) P(H_1 = j)\end{aligned}$$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$i \backslash t$		1	2	3	4
$\beta(i,t)$	0				
	1				

- initialisation:  $\beta(i,4) = 1$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\beta(i,t)$		1	2	3	4
i	t				
0					1
1					1

- initialisation:  $\beta(i,4) = 1$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\beta(i,t)$		t	1	2	3	4
i	0					1
	1					1

- réursion ( $t=4$ ):  $\beta(i,t-1) = \sum_j P(S_t = s_t | H_t = j) P(H_t = j | H_{t-1} = i) \beta(j,t)$



# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\beta(i,t)$		t	1	2	3	4
i	0					1
	1					1

◆ récursion  $\beta(0,3) = P(S_4=0 | H_4=0) P(H_4=0 | H_3=0) \beta(0,4)$   
 $+ P(S_4=0 | H_4=1) P(H_4=1 | H_3=0) \beta(1,4)$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\beta(i,t)$		1	2	3	4
i	t				
0				0.41	1
1					1

- réursion  $\beta(0,3) = 0.9 \times 0.3 \times 1 + 0.2 \times 0.7 \times 1 = 0.41$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\beta(i,t)$		1	2	3	4
i	t			0.41	1
					1

◆ récursion  $\beta(1,3) = P(S_4=0 | H_4=0) P(H_4=0 | H_3=1) \beta(0,4)$   
 $+ P(S_4=0 | H_4=1) P(H_4=1 | H_3=1) \beta(1,4)$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\beta(i,t)$		1	2	3	4
i	t				
0				0.41	1
1				0.48	1

- recursion  $\beta(1,3) = 0.9 \times 0.4 \times 1 + 0.2 \times 0.6 \times 1 = 0.48$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\beta(i,t)$		$t$	1	2	3	4
$i$	0				0.41	1
	1				0.48	1

- réursion ( $t=3$ ):  $\beta(i,t-1) = \sum_j P(S_t = s_t | H_t = j) P(H_t = j | H_{t-1} = i) \beta(j,t)$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8


Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\beta(i,t)$		1	2	3	4
i	t				
0				0.41	1
1				0.48	1



$\beta(0,2) = P(S_3=0 | H_3=0) P(H_3=0 | H_2=0) \beta(0,3)$   
 $+ P(S_3=0 | H_3=1) P(H_3=1 | H_2=0) \beta(1,3)$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\beta(i,t)$		1	2	3	4
i	t				
			0.1779	0.41	1
	1			0.48	1

- réursion  $\beta(0,2) = 0.9 \times 0.3 \times 0.41 + 0.2 \times 0.7 \times 0.48 = 0.1779$

# Programmation dynamique pour HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\beta(i,t)$		1	2	3	4
i	t				
0		0.120249	0.1779	0.41	1
1		0.105612	0.2052	0.48	1

- on continue d'appliquer la récursion jusqu'au début ( $t=1$ )...



# Lissage avec un HMM

- Les tables  $\alpha(i,t)$  et  $\beta(i,t)$  peuvent également être utilisées pour faire du lissage
  - ◆ 
$$\begin{aligned}
 P(H_k = i \mid S_{1:T}=s_{1:T}) &= \Upsilon P(H_k = i, S_{1:k}=s_{1:k}, S_{k+1:T}=s_{k+1:T}) \quad (\Upsilon \text{ est la normalisation}) \\
 &= \Upsilon P(H_k = i, S_{1:k}=s_{1:k}) P(S_{k+1:T}=s_{k+1:T} \mid H_k = i) \\
 &= \Upsilon \alpha(i,k) \beta(i,k)
 \end{aligned}$$
- On peut également faire du lissage sur deux variables cachées adjacentes
  - ◆ 
$$\begin{aligned}
 P(H_k = i, H_{k+1} = j \mid S_{1:T}=s_{1:T}) &= \Upsilon' P(H_k = i, H_{k+1} = j, S_{1:k}=s_{1:k}, S_{k+1:T}=s_{k+1:T}) \\
 &= \Upsilon' P(H_k = i, S_{1:k}=s_{1:k}) P(H_{k+1} = j \mid H_k = i) P(S_{k+1}=s_{k+1} \mid H_{k+1} = j) \\
 &\quad P(S_{k+2:T}=s_{k+2:T} \mid H_{k+1} = j) \\
 &= \Upsilon' \alpha(i,k) \beta(j,k+1) P(H_{k+1}=j \mid H_k = i) P(S_{k+1}=s_{k+1} \mid H_{k+1} = j)
 \end{aligned}$$
- À noter que  $\Upsilon$  correspond à une somme sur  $i$  seulement, tandis que  $\Upsilon'$  est une somme sur  $i$  **et**  $j$

# Lissage avec un HMM

- Exemple: décoder un message binaire avec canal bruité (T=4)
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

$\alpha(i,t)$	$i \backslash t$		...	2	...
	0	1	...	0.0175	...
	1	0	...	0.3	...

$\beta(i,t)$	$i \backslash t$		...	2	...
	0	1	...	0.1779	...
	1	0	...	0.2052	...

- on peut calculer les probabilités de lissage au temps  $t=2$

$$\begin{aligned}
 P(H_2 = 0 \mid S_1=0, S_2=1, S_3=0, S_4=0) &= \frac{\alpha(0,2) \beta(0,2)}{\sum_i \alpha(i,2) \beta(i,2)} \\
 &= \alpha(0,2) \beta(0,2) / (\alpha(0,2) \beta(0,2) + \alpha(1,2) \beta(1,2)) \\
 &= 0.0175 \times 0.1779 / (0.0175 \times 0.1779 + 0.3 \times 0.2052) \\
 &\approx 0.04813
 \end{aligned}$$

$$\begin{aligned}
 P(H_2 = 1 \mid S_1=0, S_2=1, S_3=0, S_4=0) &= 0.3 \times 0.2052 / (0.0175 \times 0.1779 + 0.3 \times 0.2052) \\
 &\approx 0.95186
 \end{aligned}$$

# Prédiction dans un HMM

- $\alpha(i,t)$  peut être utilisé pour inférer la distribution de prédiction  $\mathbf{P}(H_{t+k} | s_{1:t})$
- On utilise également un programme dynamique
  - ◆ on définit  $\pi(i,k) = P(H_{t+k} = i | S_{1:t}=s_{1:t})$
  - ◆ on note la récursion
$$\begin{aligned}\pi(i,k+1) &= P(H_{t+k+1} = i | S_{1:t}=s_{1:t}) \\ &= \sum_s \sum_j P(H_{t+k+1} = i, H_{t+k} = j, S_{t+k}=s | S_{1:t}=s_{1:t}) \\ &= \sum_s \sum_j P(S_{t+k}=s | H_{t+k}=j) P(H_{t+k+1} = i | H_{t+k}=j) P(H_{t+k} = j | S_{1:t}=s_{1:t}) \\ &= \sum_j P(H_{t+k+1} = i | H_{t+k}=j) P(H_{t+k} = j | S_{1:t}=s_{1:t}) \sum_s P(S_{t+k}=s | H_{t+k}=j) \\ &= \sum_j P(H_{t+k+1} = i | H_{t+k}=j) \pi(j,k)\end{aligned}$$
  - ◆ on a les valeurs initiales
$$\pi(i,0) = P(H_t = i | s_{1:t}) = \alpha(i,t) / \sum_j \alpha(j,t) \quad \forall i$$
- On pourrait également faire une prédiction de  $S_{t+k}$ 
  - ◆ 
$$\begin{aligned}P(S_{t+k} = s | S_{1:t}=s_{1:t}) &= \sum_j P(S_{t+k} = s | H_{t+k}=j) P(H_{t+k} = j | S_{1:t}=s_{1:t}) \\ &= \sum_j P(S_{t+k} = s | H_{t+k}=j) \pi(j,k)\end{aligned}$$

# Prédiction dans un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - on souhaite calculer la distribution de prédiction  $P(H_6=0 \mid S_1=0, S_2=1, S_3=0, S_4=0)$

Distribution d'émission


	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5



- initialisation:  $\pi(i,0) = \alpha(i,t) / \sum_j \alpha(j,t)$

# Prédiction dans un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - on souhaite calculer la distribution de prédiction  $P(H_6=0 \mid S_1=0, S_2=1, S_3=0, S_4=0)$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$

$i \backslash t$	...	4
0	...	0.04427
1	...	0.02039

$\pi(i,k)$

$i \backslash k$	0	1	2
0			
1			

- initialisation:  $\pi(0,0) = \alpha(0,4) / ( \alpha(0,4) + \alpha(1,4) )$

# Prédiction dans un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - on souhaite calculer la distribution de prédiction  $P(H_6=0 \mid S_1=0, S_2=1, S_3=0, S_4=0)$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$

$i \backslash t$	...	4
0	...	0.04427
1	...	0.02039

$\pi(i,k)$

$i \backslash k$	0	1	2
0	0.68466		
1			

- initialisation:  $\pi(0,0) = 0.04427 / (0.04427 + 0.02039) = 0.68466$

# Prédiction dans un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - on souhaite calculer la distribution de prédiction  $P(H_6=0 \mid S_1=0, S_2=1, S_3=0, S_4=0)$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$

$i \backslash t$	...	4
0	...	0.04427
1	...	0.02039

$\pi(i,k)$

$i \backslash k$	0	1	2
0	0.68466		
1	0.31534		

- initialisation:  $\pi(1,0) = 0.02039 / (0.04427 + 0.02039) = 0.31534$

# Prédiction dans un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - on souhaite calculer la distribution de prédiction  $P(H_6=0 \mid S_1=0, S_2=1, S_3=0, S_4=0)$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$

$i \backslash t$	...	4
0	...	0.04427
1	...	0.02039

$\pi(i,k)$

$i \backslash k$	0	1	2
0	0.68466		
1	0.31534		

- réursion ( $k=0$ ):  $\pi(i,k+1) = \sum_j P(H_{t+k+1} = i \mid H_{t+k} = j) \pi(j,k)$



# Prédiction dans un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - on souhaite calculer la distribution de prédiction  $P(H_6=0 \mid S_1=0, S_2=1, S_3=0, S_4=0)$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$

$i \backslash t$	...	4
0	...	0.04427
1	...	0.02039

$\pi(i,k)$

$i \backslash k$	0	1	2
0	0.68466		
1	0.31534		

- réursion ( $k=0$ ):  $\pi(0, 1) = P(H_5 = 0 \mid H_4 = 0) \pi(0,0) + P(H_5 = 0 \mid H_4 = 1) \pi(1,0)$

# Prédiction dans un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - on souhaite calculer la distribution de prédiction  $P(H_6=0 \mid S_1=0, S_2=1, S_3=0, S_4=0)$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$

$i \backslash t$	...	4
0	...	0.04427
1	...	0.02039

$\pi(i,k)$

$i \backslash k$	0	1	2
0	0.68466	0.33154	
1	0.31534		

- réursion ( $k=0$ ):  $\pi(0, 1) = 0.3 \times 0.68466 + 0.4 \times 0.31534 = 0.33154$

# Prédiction dans un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - on souhaite calculer la distribution de prédiction  $P(H_6=0 \mid S_1=0, S_2=1, S_3=0, S_4=0)$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$

$i \backslash t$	...	4
0	...	0.04427
1	...	0.02039

$\pi(i,k)$

$i \backslash k$	0	1	2
0	0.68466	0.33154	
1	0.31534		

- réursion ( $k=0$ ):  $\pi(1, 1) = P(H_5 = 1 \mid H_4 = 0) \pi(0,0) + P(H_5 = 1 \mid H_4 = 1) \pi(1,0)$

# Prédiction dans un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - on souhaite calculer la distribution de prédiction  $P(H_6=0 \mid S_1=0, S_2=1, S_3=0, S_4=0)$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$

$i \backslash t$	...	4
0	...	0.04427
1	...	0.02039

$\pi(i,k)$

$i \backslash k$	0	1	2
0	0.68466	0.33154	
1	0.31534	0.66846	

- réursion ( $k=0$ ):  $\pi(0, 1) = 0.7 \times 0.68466 + 0.6 \times 0.31534 = 0.66846$

# Prédiction dans un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - on souhaite calculer la distribution de prédiction  $P(H_6=0 \mid S_1=0, S_2=1, S_3=0, S_4=0)$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$

$i \backslash t$	...	4
0	...	0.04427
1	...	0.02039

$\pi(i,k)$

$i \backslash k$	0	1	2
0	0.68466	0.33154	0.36685
1	0.31534	0.66846	0.63315

- on continue d'appliquer la récursion jusqu'à la fin ( $k=2$ )...

# Prédiction dans un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - on souhaite calculer la distribution de prédiction  $P(H_6=0 \mid S_1=0, S_2=1, S_3=0, S_4=0)$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha(i,t)$

$i \backslash t$	...	4
0	...	0.04427
1	...	0.02039

$\pi(i,k)$

$i \backslash k$	0	1	2
0	0.68466	0.33154	0.36685
1	0.31534	0.66846	0.63315

◆  $P(H_6=0 \mid S_1=0, S_2=1, S_3=0, S_4=0) = \pi(0,2) = 0.36685$

# Explication la plus plausible avec un HMM

- On peut également éviter une énumération exponentielle

- ◆ exemple avec  $T=3$

$$\max_{h^*_{1:3}} P(h^*_1) P(s_1|h^*_1) P(h^*_2|h^*_1) P(s_2|h^*_2) P(h^*_3|h^*_2) P(s_3|h^*_3)$$

$$= \max_{h^*_3} P(s_3|h^*_3) \max_{h^*_2} P(s_2|h^*_2) P(h^*_3|h^*_2) \max_{h^*_1} P(h^*_2|h^*_1) P(h^*_1) P(s_1|h^*_1)$$

- Solution: **programmation dynamique**, avec un **max** au lieu de la somme

- ◆ on définit  $\alpha^*(i,t) = P(S_{1:t}=s_{1:t}, H_{1:t-1}=h^*_{1:t-1}, H_t=i)$

- ◆ on note la récursion

$$\begin{aligned} \alpha^*(i,t+1) &= \max_j P(S_{1:t+1}=s_{1:t+1}, H_{1:t-1}=h^*_{1:t-1}, H_t=j, H_{t+1}=i) \\ &= \max_j P(S_{t+1}=s_{t+1} \mid H_{t+1}=i) P(H_{t+1}=i \mid H_t=j) P(S_{1:t}=s_{1:t}, H_{1:t-1}=h^*_{1:t-1}, H_t=j) \\ &= P(S_{t+1}=s_{t+1} \mid H_{t+1}=i) \max_j P(H_{t+1}=i \mid H_t=j) \alpha^*(j,t) \end{aligned}$$

- ◆ on a les valeurs initiales:  $\alpha^*(i,1) = P(S_1=s_1 \mid H_1=i) P(H_1=i) \quad \forall i$

- On a alors que  $P(S_{1:T}=s_{1:T}, H_{1:T}=h^*_{1:T}) = \max_j \alpha^*(j,T)$

- On retrouve  $h^*_{1:T}$  à partir de tous les  $\operatorname{argmax}_j$

# Explication la plus plausible avec un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha^*(i,t)$		1	2	3	4
i	t				
0					
1					

- initialisation:  $\alpha^*(i,1) = P(S_1=s_1, H_1 = i) = P(S_1=s_1 \mid H_1 = i) P(H_1 = i)$



# Explication la plus plausible avec un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha^*(i,t)$	$i \backslash t$	1	2	3	4
	0	0.45			
	1				

- initialisation:  $\alpha^*(0,1) = P(S_1=0 \mid H_1=0) P(H_1=0) = 0.9 \times 0.5 = 0.45$

# Explication la plus plausible avec un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha^*(i,t)$	$i \backslash t$	1	2	3	4
0		0.45			
1		0.1			

- initialisation:  $\alpha^*(1,1) = P(S_1=0 \mid H_1=1) P(H_1=1) = 0.2 \times 0.5 = 0.1$

# Explication la plus plausible avec un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha^*(i,t)$	$i \backslash t$	1	2	3	4
0		0.45			
1		0.1			

- réursion ( $t=1$ ):  $\alpha^*(i,t+1) = P(S_{t+1}=s_{t+1} \mid H_{t+1} = i) \max_j P(H_{t+1} = i \mid H_t = j) \alpha^*(j,t)$

# Explication la plus plausible avec un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

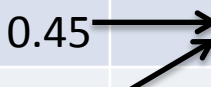
Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha^*(i,t)$		1	2	3	4
i	t				
0		0.45			
1		0.1			



- réursion:  $\alpha^*(0,2) = P(S_2=1 | H_2=0) \max\{P(H_2=0 | H_1=0) \alpha^*(0,1), P(H_2=0 | H_1=1) \alpha^*(1,1)\}$

# Explication la plus plausible avec un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha^*(i,t)$	$i \backslash t$	1	2	3	4
	0	0.45	0.0135		
	1	0.1			

- réursion:  $\alpha^*(0,2) = 0.1 \max\{ \underline{0.3 \times 0.45}, 0.4 \times 0.1 \} = 0.0135$

# Explication la plus plausible avec un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha^*(i,t)$	$i \backslash t$	1	2	3	4
	0	0.45	0.0135		
	1	0.1			

- réursion:  $\alpha^*(1,2) = P(S_2=1 | H_2=1) \max\{P(H_2=1 | H_1=0) \alpha^*(0,1), P(H_2=1 | H_1=1) \alpha^*(1,1)\}$

# Explication la plus plausible avec un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0 \mid H_t)$	0.9	0.2
$P(S_t=1 \mid H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0 \mid H_{t-1})$	0.3	0.4
$P(H_t=1 \mid H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha^*(i,t)$	$i \backslash t$	1	2	3	4
	0	0.45	0.0135		
	1	0.1	0.252		

- réursion:  $\alpha^*(1,2) = 0.8 \max\{ \underline{0.7 \times 0.45}, 0.6 \times 0.1 \} = 0.252$

# Explication la plus plausible avec un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha^*(i,t)$		$t$			
$i$		1	2	3	4
$\alpha^*(i,t)$	0	0.45	0.0135		
	1	0.1	0.252		

- réursion ( $t=2$ ):  $\alpha^*(i,t+1) = P(S_{t+1}=s_{t+1} | H_{t+1} = i) \max_j P(H_{t+1} = i | H_t = j) \alpha^*(j,t)$



# Explication la plus plausible avec un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha^*(i,t)$	$i \backslash t$	1	2	3	4
0		0.45	0.0135	0.09072	
1		0.1	0.252		

- réursion:  $\alpha^*(0,3) = 0.9 \max\{0.3 \times 0.0135, \underline{0.4 \times 0.252}\} = 0.09072$

# Explication la plus plausible avec un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha^*(i,t)$	$i \backslash t$				
		1	2	3	4
0		0.45	0.0135	0.09072	0.02449
1		0.1	0.252	0.03024	0.01270

- on continue d'appliquer la récursion jusqu'à la fin ( $t=4$ )...

# Explication la plus plausible avec un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha^*(i,t)$	$i \backslash t$	1	2	3	4
	0	0.45	0.0135	0.09072	0.02449
	1	0.1	0.252	0.03024	0.01270

- on trouve le maximum à la dernière colonne...

# Explication la plus plausible avec un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha^*(i,t)$		1	2	3	4
i	t				
0		0.45	0.0135	0.09072	0.02449
1		0.1	0.252	0.03024	0.01270

- ... puis on retrouve le chemin associé aux maxima précédents

# Explication la plus plausible avec un HMM

- Exemple: décoder un message binaire avec canal bruité ( $T=4$ )
  - message observé:  $S_1=0, S_2=1, S_3=0, S_4=0$

Distribution d'émission

	$H_t=0$	$H_t=1$
$P(S_t=0   H_t)$	0.9	0.2
$P(S_t=1   H_t)$	0.1	0.8

Distribution de transition

	$H_{t-1}=0$	$H_{t-1}=1$
$P(H_t=0   H_{t-1})$	0.3	0.4
$P(H_t=1   H_{t-1})$	0.7	0.6

Distribution initiale

	$H_1=0$	$H_1=1$
$P(H_1)$	0.5	0.5

$\alpha^*(i,t)$		1	2	3	4
i	t				
0		0.45	0.0135	0.09072	0.02449
1		0.1	0.252	0.03024	0.01270

$H_1=0$        $H_2=1$        $H_3=0$        $H_4=0$

- ce chemin nous donne la séquence des  $H_t$  la plus probable

# Au delà du HMM

- **Filtre de Kalman:** cas où les variables d'observation et cachées ne sont pas discrètes mais sont plutôt réelles
  - ◆ voir livre de référence, section 15.4
- **État caché avec structure complexe:** cas où il n'est pas possible de faire une sommation exacte sur toutes les configurations de l'état caché
  - ◆ on doit alors approximer l'inférence
  - ◆ **filtre particulaire** (*particle filter*): inférence approximative basée sur l'échantillonnage, où on maintient une population stochastique de configurations (particules) de l'état caché
  - ◆ à chaque temps  $t$ , on met à jour notre population de particules en tenant compte des nouvelles observations
  - ◆ voir livre de référence, section 15.5.3

# Application: reconnaissance vocale

- La reconnaissance vocale est difficile:
  - ◆ bruit ambiant ou introduit par la digitalisation
  - ◆ variations dans la prononciation
  - ◆ différents mots ont la même prononciation
- Problème: Quelle est la séquence de mots la plus vraisemblable étant donné un signal sonore ?
- Réponse: Choisir la séquence de mots la plus probable a posteriori
  - ◆  $\operatorname{argmax}_{\text{mots}} P(\text{mots} \mid \text{signal}) = \operatorname{argmax}_{\text{mots}} \alpha P(\text{mots}, \text{signal})$

# Modèle acoustique et modèle du langage

- En utilisant la règle de Bayes
  - ◆  $P(\text{mots} \mid \text{signal}) = \alpha P(\text{signal} \mid \text{mots}) P(\text{mots})$
- On peut donc décomposer le problème en deux:
  - ◆  $P(\text{Signal} \mid \text{Mots})$ : **modèle acoustique**
  - ◆  $P(\text{Mots})$ : **modèle de langage** (plus de détails à venir dans le cours...)
- Chaîne cachée: les mots
- Chaîne observée: le signal



# Phones et phonèmes

- Des travaux dans le domaine de phonologie ont montré que toutes les langues humaines sont basées sur un sous-ensemble d'environ 100 sons, appelés **phones**, communs à toutes les langues
- Les phones découlent de l'articulation des lèvres, des dents, de la langue, des cordes vocales et du flux de l'air
- Intuitivement, un phone est un son qui correspond à une seule consonne ou une seule voyelle
- Mais c'est plus subtil ! Des combinaisons de consonnes comme « th » ou « ng » en anglais ont chacun leur phone
- Un **phonème** est la plus petite unité de son distinctive que l'on puisse isoler par segmentation dans un mot
- Un phonème sera associé à un ou plusieurs phones qui peuvent être interchangés sans changer la compréhension d'un mot
  - ◆ phonème /k/: phones [k] (« *cat* », « *kit* ») et [k<sup>h</sup>] (« *school* », « *skill* »)

# Phones: exemple

- Phones pour l'anglais américain:


[iy]	b <u>ea</u> t	[b]	b <u>e</u> t	[p]	<u>p</u> et
[ih]	b <u>i</u> t	[ch]	<u>Ch</u> et	[r]	<u>r</u> at
[ey]	b <u>e</u> t	[d]	<u>d</u> ebt	[s]	<u>s</u> et
[ao]	b <u>ou</u> ght	[hh]	<u>h</u> at	[th]	<u>th</u> ick
[ow]	b <u>oa</u> t	[hv]	<u>h</u> igh	[dh]	<u>th</u> at
[er]	B <u>e</u> rt	[l]	<u>l</u> et	[w]	<u>w</u> et
[ix]	ros <u>e</u> s	[ng]	s <u>ing</u>	[en]	butt <u>on</u>
:	:	:	:	:	:

# Modèle acoustique

- Rappel:
  - ◆  $P(\text{Mots} \mid \text{Signal}) = \alpha P(\text{Signal} \mid \text{Mots}) P(\text{Mots})$ 
    - »  $P(\text{Signal} \mid \text{Mots})$ : modèle acoustique
    - »  $P(\text{Mots})$ : modèle de langage
- L'existence des phones permet de diviser le modèle acoustique en deux autres parties:
  - ◆ **modèle de prononciation**: spécifie, pour chaque mot, une distribution de probabilités sur une séquence de phones
    - » par exemple, « *ceiling* » est parfois prononcé [s iy l ih ng], ou [s iy l ix ng], ou encore [s iy l en]
    - » le phone est une variable cachée, le signal est la variable observée
  - ◆ **modèle phonique**: le modèle phonique  $P(e_t \mid x_t)$  donne la probabilité que le signal échantillonné soit observé au temps  $t$  si le phone est  $x_t$

# Exemple de modèle de prononciation

- Modèle de prononciation
  - ◆  $P([\text{towmeytow}] | \text{« tomato »}) = P([\text{towmaatow}] | \text{« tomato »}) = 0.1$
  - ◆  $P([\text{tahmeytow}] | \text{« tomato »}) = P([\text{tahmaatow}] | \text{« tomato »}) = 0.4$
- Les transitions sont spécifiées manuellement
- Les probabilités sont apprises



# Applications

- Reconnaissance vocale
  - ◆ CMU Sphinx (publique):  
<http://cmusphinx.sourceforge.net/html/download.php>
  - ◆ Dragon Naturally Speaking (commercial)
  - ◆ IBM ViaVoice (commercial)
- Reconnaissance de caractères
  - ◆ variables observées: pixels d'une image
  - ◆ variables cachées: mots écrits
- Suivi d'objets dans une vidéo (*object tracking*)
  - ◆ variables observées: pixels d'une image, dans le *frame*  $t$
  - ◆ variables cachées: la position  $x_t, y_t$  de l'objet dans le *frame*